

Projet Ma316 - BE

Institut Polytechnique des Sciences Avancées (IPSA)



Équations et Algorithmes Avancés

Réalisé par :

Romain Lefol, Killian Belloc, Jean Tixeront, Willen Arab, Guilhem Perret-bardou, Hugo Dubouchet

Encadrants :

M. G. Couffignal, M. El-Mahboub

Année académique : 2024-2025

18 Décembre 2024

Table des matières

1	Équation d'Euler-Lagrange à deux variables	4
1.1	Calcul de la dérivée directionnelle:	4
1.2	Formule d'intégration par parties a deux variables	5
1.3	Vérifications des points critiques u de S sur Ω	6
1.4	Application	7
1.4.1	Question de physique	7
1.4.2	Mouvement de la corde	7
1.4.3	lagrangien a poser et interprétation physique	9
2	Une généralisation du gradient conjugué	10
2.1	Somme de deux fonctions convexes	10
2.2	Critère de connexité de f en fonction de A	11
2.3	Critère de convexité pour J	11
2.4	Minimum global	11
2.5	Dérivée directionnelle de J en x dans la direction h	12
2.6	Critères de convexité de J	12
2.7	Minimum global x de J avec $\nabla J(x) = 0$	13
2.8	Version générale de l'algorithme du gradient conjugué	14
2.9	Ecart théorique entre deux itérés	14
2.10	Python de l'algorithme du gradient conjugué de la question précédente	15
2.11	Application	15
2.11.1	J une fonction quadratique sur $(E, \langle \cdot, \cdot \rangle)$	16
2.11.2	Minimum de J	16
2.11.3	Les minimas de J et l'équation de Sylvester (S)	16
2.11.4	Test de algorithme	16
3	En mélangeant tout ça...	18
3.1	Un problème d'électrostatique	18
3.1.1	Équation vérifiée par un point critique de S	18
3.2	De l'interpolation guidé avec l'équation de Poisson.	22
3.2.1	Equation vérifie par un point critique de S	22
3.2.2	Application 1 :	26
4	Conclusion	28

Table des Illustrations

1	Portrait de Leonhard Euler (1707-1783)	7
2	Portrait de Jean le Rond d'Alembert (1717-1783)	8
3	Portrait de James Joseph Sylvester (1814-1897)	15
4	Portrait de Siméon Denis Poisson (1781-1840)	18
5	Représentation du potentiel électrique	20
6	Représentation du champ électrique et du potentiel electro-statique	21
7	Représentation du champ électrique et du potentiel electro-statique	21
8	Représentation du multithreading et du single-thread.	22
9	Portrait de Jacques Hadamard (1865-1963)	23
10	Image avant le programme	26
11	Image après le programme	26
12	Image avant le programme	27
13	Image après le programme	27

Lexique

∇f (**Gradient**) : le gradient d'une fonction f est un vecteur colonne qui peut être aussi interpréter sous forme de matrice qui contient les dérivées partielles variable par variable.

Δf (**Laplacien**) : le laplacien d'une fonction f est la somme de ses dérivées partielles secondes variables par variables.

$\frac{\partial f}{\partial x_i}$ (**Dérivée partielle**) : est une notion de calcul différentiel utilisée pour analyser comment une fonction dépend de plusieurs variables indépendantes. Lorsque l'on calcule une dérivée partielle, on considère qu'une variable change tandis que les autres restent constantes.

$\int_C f ds$ (**Intégrale avec contour**) : Désigne une intégrale de contour ou intégrale curviligne **fermée**. Elle est utilisée lorsque l'on intègre une fonction le long d'un chemin fermé (c'est-à-dire une courbe qui revient à son point de départ).

$Div(f)$ (**La divergence**) : est une opération vectorielle qui mesure la variation nette d'un champ vectoriel en un point donné, c'est-à-dire si ce point agit comme une "source" ou un "puits" pour ce champ. Elle est utilisée en physique et en mathématiques pour analyser des champs vectoriels tels que les champs de vitesse, électriques ou magnétiques.

$\langle \cdot, \cdot \rangle$ (**Le produit scalaire**) : est une opération algébrique qui prend deux vecteurs et renvoie un scalaire (un nombre). Il est utilisé pour mesurer la relation entre les directions et les longueurs des vecteurs.

$\| \cdot \|$ (**La norme**) : Il s'agit de la mesure de la "longueur" ou de la "magnitude" d'un vecteur. Elle quantifie la distance entre l'origine (le point zéro) et l'extrémité du vecteur dans un espace vectoriel.

Introduction à l'optimisation convexe

L'optimisation convexe est une branche des mathématiques appliquées qui se concentre sur la résolution de problèmes. Un problème d'optimisation convexe peut être formulé de manière générale comme suit :

$$\begin{aligned} \min_{x \in \mathbb{R}^n} \quad & f_0(x) \\ \text{sous contraintes} \quad & f_i(x) \leq 0, \quad i = 1, \dots, m, \\ & h_j(x) = 0, \quad j = 1, \dots, p, \end{aligned}$$

où $f_0(x)$ (fonction objectif) et $f_i(x)$ (fonctions de contrainte) sont convexes, et $h_j(x)$ (contraintes d'égalité) sont affines.

Caractéristiques et propriétés de la convexité

La convexité est une propriété fondamentale qui garantit plusieurs avantages :

- **Unicité des solutions globales** : Dans les problèmes convexes, tout minimum local est également un minimum global.
- **Facilité de résolution** : Les problèmes convexes peuvent être résolus efficacement à l'aide d'algorithmes tels que la méthode du gradient, les algorithmes de points intérieurs, et les méthodes duales. Ces techniques permettent de résoudre des problèmes complexes même pour des dimensions élevées.
- **Robustesse et stabilité** : Les solutions des problèmes convexes sont souvent moins sensibles aux perturbations ou erreurs dans les données d'entrée, ce qui les rend particulièrement utiles dans les applications pratiques.

Applications de l'optimisation convexe

L'optimisation convexe est largement utilisée dans des domaines variés, notamment :

- **Finance** : Gestion de portefeuille et contrôle du risque.
- **Ingénierie** : Conception optimale en génie civil, mécanique, et électrique.
- **Apprentissage automatique** : Ajustement de modèles, régression et classification.
- **Télécommunications** : Allocation de ressources et optimisation des réseaux.

Comme Boyd et Vandenberghe l'expliquent, l'optimisation convexe est devenue un outil essentiel grâce à sa capacité à modéliser des problèmes complexes tout en garantissant des solutions fiables et rapides. Elle sert souvent de base dans le développement de modèles plus avancés, tels que l'optimisation multicritère ou les systèmes embarqués, où des décisions en temps réel doivent être prises de manière automatique et efficace.

Référence

Stephen Boyd, Lieven Vandenberghe, *Convex Optimization*, Cambridge University Press, 2004.



UNIVERSITY OF
CAMBRIDGE

1 Équation d'Euler-Lagrange à deux variables

Dans cette partie, nous allons étendre (très légèrement... on pourrait faire bien mieux...) les calculs effectués lors du TD1 de ce module à des actions données par des intégrales doubles (et non plus uniquement d'une seule variable que nous avons notée t). En effet, en TD, nous avons résolu le problème de la recherche des points critiques d'une fonctionnelle d'action donnée par un lagrangien. Nous avons interprété dans les cadres physiques classiques la forme de tels lagrangiens comme la formalisation des « contraintes » qui « contraignent » la trajectoire de notre système physique étudié dans son espace de configuration (= ses degrés de liberté). Ces contraintes étant supposées décrites localement (temporellement parlant) par le lagrangien, l'action incarne la somme (sur le temps) de toutes ces contraintes. Dans cette partie, nous allons dépasser ce cadre restreint à la seule variable temporelle et nous considérerons des actions données par des intégrales doubles. Plaçons-nous dans le cadre variationnel suivant :

- $\Omega \subset \mathbb{R}^2$ est un domaine fermé et borné du plan. On supposera que la frontière $\partial\Omega$ (:= le bord) de Ω est décrit par une courbe paramétrique orientée $\gamma : [0, 1] \rightarrow \partial\Omega \subset \mathbb{R}^2$ de classe C^2 . Cette courbe formera un lacet, i.e. une courbe paramétrique fermée où $\gamma(0) = \gamma(1)$. On notera x, y les variables de Ω .
- Nous prendrons comme espace des configurations : $C = \mathbb{R}$. Il n'y aura donc qu'un seul degré de liberté ici.
- On prendra pour espace des historiques : $H := C^2(\Omega, C)$.

On notera un élément de H par : $u : \Omega \rightarrow C$ et l'on notera $\partial_x u := \frac{\partial u}{\partial x}$ et $\partial_y u := \frac{\partial u}{\partial y}$ les dérivées partielles par rapport à la première, respectivement seconde, variable de Ω .

On considérera l'action lagrangienne à deux variables de la forme :

$$S : H \rightarrow \mathbb{R}, \quad u \mapsto S(u) := \int \int_{\Omega} L(u, \partial_x u, \partial_y u, x, y) dx dy$$

où L est une fonction deux fois différentiable : $L : C \times C \times C \times \Omega \rightarrow \mathbb{R}$ que l'on appellera encore lagrangien de l'action S .

1.1 Calcul de la dérivée directionnelle:

Fixons $v : \Omega \rightarrow C \in H$. On cherche à calculer $D_v S(u)$ la dérivée directionnelle de $S(u)$ dans la direction v . Pour cela on va utiliser la définition de la dérivée directionnelle.

Définition dérivée directionnelle :

Soit $f : \mathbb{R}^n \rightarrow \mathbb{R}$ une fonction différentiable et $v \in \mathbb{R}^n$ un vecteur non nul (appelé **direction**). La dérivée directionnelle de f en un point $x \in \mathbb{R}^n$ dans la direction de v est définie par :

$$D_v f(x) = \lim_{t \rightarrow 0} \frac{f(x + tv) - f(x)}{t},$$

si cette limite existe.

Sachant que l'on a :

$$L(u + v, \partial_x u + v, \partial_y u + v, x + v, y + v) = L(u, \partial_x u, \partial_y u, x, y) + \nabla_{u, \partial_x u, \partial_y u, x, y} L \cdot v(x, y) + o(\|v\|)$$

Donc :

$$D_v S(u) = \lim_{\varepsilon \rightarrow 0} \frac{\int \int_{\Omega} L(u + v, \partial_x u + v, \partial_y u + v, x + v, y + v) - L(u, \partial_x u, \partial_y u, x, y)}{\varepsilon} dx dy$$

$$D_v S(u) = \lim_{\varepsilon \rightarrow 0} \int \int_{\Omega} \frac{L(u, \partial_x u, \partial_y u, x, y) + \nabla_{u, \partial_x u, \partial_y u, x, y} L \cdot \begin{pmatrix} \varepsilon v \\ \varepsilon v \\ \varepsilon v \\ 0 \\ 0 \end{pmatrix}^T + o(\|v\|) - L(u, \partial_x u, \partial_y u, x, y)}{\varepsilon} dx dy$$

$$D_v S(u) = \iint_{\Omega} \nabla_{u, \partial_x u, \partial_y u, x, y} L \cdot \begin{pmatrix} v \\ v \\ v \\ 0 \\ 0 \end{pmatrix}^T dx dy$$

Ainsi, on a la dérivée directionnelle $D_v S(u)$:

$$D_v S(u) = \iint_{\Omega} \left(\frac{\partial L}{\partial u} v + \frac{\partial L}{\partial(\partial_x u)} \partial_x v + \frac{\partial L}{\partial(\partial_y u)} \partial_y v \right) dx dy$$

1.2 Formule d'intégration par parties a deux variables

Notons la forme différentielle :

$$d\omega := -P(x, y) dx + Q(x, y) dy$$

où :

$$\begin{cases} P(x, y) := v(x, y) \frac{\partial L}{\partial(\partial_y u)}(u(x, y), \partial_x u(x, y), \partial_y u(x, y), x, y), \\ Q(x, y) := v(x, y) \frac{\partial L}{\partial(\partial_x u)}(u(x, y), \partial_x u(x, y), \partial_y u(x, y), x, y). \end{cases}$$

On rappelle le théorème de Green-Riemann.

Théorème : GREEN-RIEMANN

Soit w une forme différentielle de classe C^1 sur un ouvert $\mathcal{O} \subset \mathbb{R}^2$ telle que $w(x, y) = P(x, y) dx + Q(x, y) dy$. Soit $\mathcal{D} \subset \mathcal{O}$ un ensemble fermé et borné (un compact) de $\mathbb{R}^2$ dont la frontière $\partial\mathcal{D}$ est une courbe paramétrique de classe C^1 orientée dans le sens positif. Alors

$$\oint_{\partial\mathcal{D}^+} w(x, y) = \iint_{\mathcal{D}} \left(\frac{\partial Q}{\partial x}(x, y) - \frac{\partial P}{\partial y}(x, y) \right) dx dy.$$

Dans notre cas on note $d\omega$:

$$d\omega = -P(x, y) dx + Q(x, y) dy$$

Ainsi en appliquant l'énoncé du théorème de Green-Riemann on obtient :

$$\iint_{\Omega} \left(\frac{\partial Q}{\partial x} + \frac{\partial P}{\partial y} \right) dx dy = \int_{\partial\Omega} -P dx + Q dy$$

On nous donne les expressions de $P(x, y)$ et de $Q(x, y)$ tel que :

$$\begin{cases} P(x, y) = v(x, y) \frac{\partial L}{\partial(\partial_y u)}(u(x, y), \partial_x u(x, y), \partial_y u(x, y), x, y), \\ Q(x, y) = v(x, y) \frac{\partial L}{\partial(\partial_x u)}(u(x, y), \partial_x u(x, y), \partial_y u(x, y), x, y). \end{cases}$$

On a ainsi les dérivés partielles de $P(x, y)$ et de $Q(x, y)$:

$$\begin{cases} \frac{\partial P}{\partial y} = \frac{\partial v}{\partial y} \frac{\partial L}{\partial(\partial_y u)} + v \frac{\partial}{\partial y} \left(\frac{\partial L}{\partial(\partial_y u)} \right), \\ \frac{\partial Q}{\partial x} = \frac{\partial v}{\partial x} \frac{\partial L}{\partial(\partial_x u)} + v \frac{\partial}{\partial x} \left(\frac{\partial L}{\partial(\partial_x u)} \right). \end{cases}$$

$$\iint_{\Omega} \left(\frac{dv}{dx} \frac{\partial L}{\partial(\partial_x u)} + \frac{dv}{dy} \frac{\partial L}{\partial(\partial_y u)} + v \left(\frac{d}{dx} \frac{\partial L}{\partial(\partial_x u)} + \frac{d}{dy} \frac{\partial L}{\partial(\partial_y u)} \right) \right) dx dy = \int_{\partial\Omega} P dx + Q dy$$

On effectue une intégration par partie en intégrant le v des deux côtés de plus, on considère v à la frontière de Ω , alors :

$$\iint_{\Omega} \left(\frac{\partial L}{\partial(\partial_x u)} dx v + \frac{\partial L}{\partial(\partial_y u)} dy v \right) dx dy = \int_{\partial\Omega} P dx + Q dy - \iint_{\Omega} v \left(\frac{d}{dx} \frac{\partial L}{\partial(\partial_x u)} + \frac{d}{dy} \frac{\partial L}{\partial(\partial_y u)} \right) dx dy$$

1.3 Vérifications des points critiques u de S sur Ω

On suppose que $v(x, y) = 0$ pour tout $(x, y) \in \partial\Omega$.

On rappelle le lemme fondamental du calcul variationnel.

Lemme fondamental du calcul variationnel:

Soit $f : [a, b] \rightarrow \mathbb{R}$ une fonction continue telle que :

$$\int_a^b f(x)g(x) dx = 0$$

pour toute fonction $g : [a, b] \rightarrow \mathbb{R}$, **continue et à valeurs réelles**, ayant la propriété que $g(a) = g(b) = 0$. Alors, on en déduit que $f(x) = 0$ pour tout $x \in [a, b]$.

On a vu que les points critiques U de S vérifient sur Ω , $D_v S(u) = 0$ donc :

$$\iint_{\Omega} \left(\frac{\partial L}{\partial u} v + \frac{\partial L}{\partial(\partial_x u)} dx v + \frac{\partial L}{\partial(\partial_y u)} dy v \right) dx dy = 0$$

On sépare l'intégrale en deux :

$$\iint_{\Omega} \left(\frac{\partial L}{\partial u} v \right) dx dy + \iint_{\Omega} \left(\frac{\partial L}{\partial(\partial_x u)} \partial_x v + \frac{\partial L}{\partial(\partial_y u)} \partial_y v \right) dx dy = 0$$

Or à la question 2 on a vu que

$$\begin{aligned} \iint_{\Omega} \left(\frac{\partial L}{\partial(\partial_x u)} dx v + \frac{\partial L}{\partial(\partial_y u)} dy v \right) dx dy &= \int_{\partial\Omega} P dx + Q dy - \iint_{\Omega} v \left(\frac{d}{dx} \frac{\partial L}{\partial(\partial_x u)} + \frac{d}{dy} \frac{\partial L}{\partial(\partial_y u)} \right) dx dy \\ \iff \iint_{\Omega} \left(\frac{\partial L}{\partial u} v \right) dx dy + \int_{\partial\Omega} P dx + Q dy - \iint_{\Omega} \left(v \left(\frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right) \right) \right) dx dy &= 0 \end{aligned}$$

D'après l'énoncé on sait que $v(x, y) = 0$, $\forall (x, y) \in \partial\Omega$ donc on peut dire que

$$\int_{\partial\Omega} P dx + Q dy = 0$$

Ainsi :

$$\begin{aligned} \iint_{\Omega} \left(\frac{\partial L}{\partial u} v - v \left(\frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right) \right) \right) dx dy &= 0 \\ \iint_{\Omega} \left(\frac{\partial L}{\partial u} - \left(\frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right) \right) \right) v dx dy &= 0 \end{aligned}$$

Donc par l'application du lemme fondamental du calcul variation on peut dire que :

$$\left(\frac{\partial L}{\partial u} - \left(\frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right) \right) \right) v = 0$$

On obtient ainsi les équations d'Euler-Lagrange à deux variables que nous cherchions.

$$\boxed{\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right)}$$

Petit point d'intérêt sur les Équations d'Euler-Lagrange

Les **équations d'Euler-Lagrange**, formulées par **Leonhard Euler (1707-1783)**, sont des outils clés en mécanique et optimisation. Elles permettent de décrire les trajectoires d'un système dynamique en minimisant l'action, une quantité associée à l'énergie cinétique et potentielle. Ces équations sont cruciales en **optimisation**, où elles servent à trouver des solutions minimales ou maximales dans divers problèmes, comme ceux de contrôle optimal. En traitement d'images, elles sont utilisées pour des tâches comme la reconstruction et le débruitage d'images en minimisant une fonction d'énergie, ce qui est essentiel pour améliorer la qualité des images dégradées. Euler, pionnier dans de nombreux domaines des mathématiques, a contribué de manière essentielle à la formulation de concepts qui influencent encore aujourd'hui les sciences et la technologie.



Figure 1: Portrait de Leonhard Euler (1707-1783)

1.4 Application

On considère une corde de longueur L dans un repère orthonormé (e_x, e_y) et on note : $u(x, t)$ la hauteur sur l'axe e_y en fonction de la position x et du temps t . On posera : $\Omega = [t_0, t_f] \times [0, L]$ et on supposera que u est une fonction de classe C^2 . Le lagrangien étant l'expression locale des contraintes agissantes sur la « trajectoire » dans l'espace des degrés de libertés de notre système physique. Nous supposons ici qu'il est de la forme :

$$L(u, \partial_x u, \partial_t u, x, t) := \frac{1}{2} \rho (\partial_t u(x, t))^2 - f(\partial_x u(x, t))$$

où ρ est la densité linéique de la corde et $f : \mathbb{R} \rightarrow \mathbb{R}$ est une fonction que nous supposons de classe C^2 .

1.4.1 Question de physique

On considère une corde de longueur L dans un repère orthonormé (e_x, e_y) et on note : $u(x, t)$ la hauteur sur l'axe e_y en fonction de la position x et du temps t . On posera :

$$\Omega = [t_0, t_f] \times [0, L]$$

Et on supposera que u est une fonction de classe C^2 . Le lagrangien étant l'expression locale des contraintes agissantes sur la « trajectoire » dans l'espace des degrés de libertés de notre système physique. Nous supposons ici qu'il est de la forme :

$$L(u, \partial_x u, \partial_t u, x, t) = \frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_x u(x, t))$$

D'après la formule du lagrangien donnée précédemment, nous pouvons physiquement en déduire que $\frac{1}{2} \rho \partial_t u(x, t)^2$ et $f(\partial_x u(x, t))$ sont homogènes à une énergie et on identifie le membre de gauche comme l'énergie cinétique et le membre de droite comme une énergie potentielle.

1.4.2 Mouvement de la corde

On note :

$$\partial_{t,t} u(x, t) := \frac{\partial^2 u}{\partial t^2}(x, t) \quad \text{et} \quad \partial_{x,x} u(x, t) := \frac{\partial^2 u}{\partial x^2}(x, t)$$

Ainsi que l'équation de d'Alembert :

$$\partial_{t,t} u(x, t) - c^2 \partial_{x,x} u(x, t) = 0$$

où c est la vitesse de propagation de l'onde dans le milieu considéré.

Montrons que

$$\rho \frac{\partial^2 u}{\partial t^2}(x, t) - f'' \left(\frac{\partial u(x, t)}{\partial x} \right) \frac{\partial u(x, t)}{\partial x^2} = 0$$

Partons de la question 3

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial L}{\partial (\partial_x u)} \right) + \frac{d}{dt} \left(\frac{\partial L}{\partial (\partial_t u)} \right)$$

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial}{\partial_x u} \left(\frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_t u(x, t)) \right) \right) + \frac{d}{dt} \left(\frac{\partial}{\partial_t u} \left(\frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_t u(x, t)) \right) \right)$$

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial}{\partial_x u} (-f(\partial_t u(x, t))) \right) + \frac{d}{dt} \left(\frac{\partial}{\partial_t u} \left(\frac{1}{2} \rho \partial_t u(x, t)^2 \right) \right)$$

$$\frac{\partial L}{\partial u} = -\partial_{x,x} f''(\partial_t u(x, t)) + \rho \partial_{t,t} u(x, t)$$

$$\text{Or, } \frac{\partial L}{\partial u} = 0$$

D'où,

$$\boxed{-\partial_{x,x} f''(\partial_t u(x, t)) + \rho \partial_{t,t} u(x, t) = 0}$$

Par ailleurs, si nous supposons que f est une fonction quadratique convexe nous avons :

$$\frac{f''(\partial_x u(x, t))}{\rho} = c^2$$

$$\iff f''(\partial_x u(x, t)) = c^2 \rho$$

$$\iff f'(\partial_x u(x, t)) = c^2 \rho \partial_x u(x, t) + K_1$$

$$\iff f(\partial_x u(x, t)) = \frac{1}{2} c^2 \rho (\partial_x u(x, t))^2 + K_1 \partial_x u(x, t) = K_2$$

Les Équations de D'Alembert et leur Lien avec les Équations d'Euler-Lagrange

Formulées par **Jean le Rond d'Alembert (1717-1783)**, Les **équations de D'Alembert**, décrivent le mouvement des systèmes dynamiques avec contraintes en introduisant des forces d'inertie. Ce travail a jeté les bases de la **mécanique analytique** et a directement influencé la formulation des **équations d'Euler-Lagrange**, qui relient les forces d'un système à son mouvement en minimisant l'action. D'Alembert, pionnier des mathématiques et de la physique, a contribué à l'élargissement des principes de Newton et a permis de simplifier l'analyse des systèmes dynamiques complexes. Ses travaux ont également des applications modernes, comme dans le **traitement d'images**, où les équations de Lagrange et Euler-Lagrange sont utilisées pour optimiser des processus tels que la reconstruction et le débruitage d'images.



Figure 2: Portrait de Jean le Rond d'Alembert (1717-1783)

Et de cela on peut finalement déduire l'équation de d'Alembert :

$$\boxed{\frac{\partial^2 u}{\partial t^2}(x, t) - c^2 \frac{\partial^2 u}{\partial x^2}(x, t) = 0}$$

Cela caractérise la propagation de l'onde dans le milieu considéré.

Cette hypothèse sur f peut être interprétée comme le fait que l'énergie potentielle du milieu augmente avec les contraintes.

1.4.3 lagrangien a poser et interprétation physique

Soit s une fonction définie sur Ω à valeurs réelles. En posant le lagrangien suivant :

$$L(u, \partial_x u, \partial_t u, x, t) := \frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_x u(x, t)) - \frac{s(x, y)^2}{2} u(x, t)$$

Nous obtenons l'équation des ondes avec la source suivante

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial}{\partial_x u} \left[\frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_x u(x, t)) - \frac{s(x, y)^2}{2} u(x, t) \right] \right) + \frac{d}{dt} \left(\frac{\partial}{\partial_t u} \left[L \left(\frac{1}{2} \rho \partial_t u(x, t)^2 - f(\partial_x u(x, t)) - \frac{s(x, y)^2}{2} u(x, t) \right) \right] \right)$$

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(-\frac{\partial}{\partial_x u} \left[f(\partial_x u(x, t)) - \frac{s(x, y)^2}{2} u(x, t) \right] \right) + \frac{d}{dt} \left(\frac{\partial}{\partial_t u} \left[L \left(\frac{1}{2} \partial_t u(x, t)^2 - \frac{s(x, y)^2}{2} \right) \right] \right) + \frac{d}{dt} \left[\partial_t u(x, t) - \frac{s(x, y)^2}{2} \right]$$

$$= -\partial_{x,x} u(x, t) f''(\partial_x u(x, t)) - s(x, y) + \partial_{t,t} u(x, t) \quad (f \circ g)' = g' \cdot f' \circ g$$

$$\boxed{s(x, y) = -\partial_{x,x} u(x, t) f''(\partial_x u(x, t)) + \partial_{t,t} u(x, t)}$$

Cette contrainte sur le lagrangien peut être interprétée comme le fait que la force n'est pas totalement conservative une partie qui ne dérive pas d'une énergie potentielle.

2 Une généralisation du gradient conjugué

On se placera dans toute cette partie sur un espace vectoriel de dimension fini E muni d'un produit scalaire, $\langle \cdot, \cdot \rangle$ et de la norme associée $\| \cdot \|$. Nous dirons qu'une application linéaire $A : E \rightarrow E$ est *symétrique* si pour tout $(x, y) \in E^2$:

$$\langle x, A(y) \rangle = \langle A(x), y \rangle$$

et nous dirons que A est *semi-définie positive* si $x \in E$:

$$\langle x, A(x) \rangle \geq 0$$

Nous dirons qu'elle est *définie positive* si l'inégalité est stricte pour tout $x \in E \setminus \{0_E\}$.

On définit une fonction quadratique sur $(E, \langle \cdot, \cdot \rangle)$ par une fonction de la forme pour $x \in E$:

$$J(x) := \frac{1}{2} \langle x, A(x) \rangle - \langle b, x \rangle$$

où A est une application linéaire symétrique, $b \in E$.

2.1 Somme de deux fonctions convexes

On pose la définition de la convexité :

Définition convexité :

Étant donné un ensemble convexe $X \subset \mathbb{R}^n$, une fonction à valeurs réelles $f : X \rightarrow \mathbb{R}$ est convexe si pour toute paire de points $x, y \in X$

$$f(\theta x + (1 - \theta)y) \leq \theta f(x) + (1 - \theta)f(y) \quad \forall \theta \in [0, 1].$$

Soit g_1, g_2 deux fonctions convexes sur E .

On pose :

$$g(x) = g_1(x) + g_2(x)$$

Montrons que $g(x)$ est convexe :

$$\forall (x, y) \in E^2 \quad \text{et} \quad \lambda \in [0, 1], \text{ On a :}$$

$$g(\lambda x + (1 - \lambda)y) = g_1(\lambda x + (1 - \lambda)y) + g_2(\lambda x + (1 - \lambda)y)$$

Or comme g_1, g_2 convexes, On applique la def :

$$\begin{cases} g_1(\lambda x + (1 - \lambda)y) \leq \lambda g_1(x) + (1 - \lambda)g_1(y) \\ g_2(\lambda x + (1 - \lambda)y) \leq \lambda g_2(x) + (1 - \lambda)g_2(y) \end{cases}$$

On additionne les inégalité :

$$g(\lambda x + (1 - \lambda)y) \leq \lambda g_1(x) + (1 - \lambda)g_1(y) + \lambda g_2(x) + (1 - \lambda)g_2(y)$$

$$\iff g(\lambda x + (1 - \lambda)y) \leq \lambda (g_1(x) + g_2(x)) + (1 - \lambda) (g_1(y) + g_2(y))$$

$$\iff g(\lambda x + (1 - \lambda)y) \leq \lambda g(x) + (1 - \lambda)g(y)$$

Donc la somme de fonctions convexes est aussi convexe (de même pour les fonctions concave). On ajoutera qu'avec la même méthode, on voit également que la somme d'une fonction convexe et d'une fonction strictement convexe est nécessairement strictement convexe.

2.2 Critère de conexité de f en fonction de A

Notons : $f : x \mapsto \langle x, A(x) \rangle$ où A est une application linéaire symétrique.

On a :

$$f(x) = \langle x, A(x) \rangle = x^T A x$$

Ce qui signifie que f est de classe C^∞ car $x^T A x$ est une forme quadratique. Ainsi, f est convexe si et seulement si le hessien de $f : \nabla^2 f(x)$ est une matrice semi définie positive pour tout $x \in E$.

Or :

$$\nabla^2 f(x) = \nabla(\nabla f(x)) = \nabla(2Ax) = 2A$$

Donc le hessien de f est une matrice semi définie positive uniquement si A en est aussi une. Ainsi, f est convexe si et seulement si A est une matrice semi définie positive. De la même manière, f est strictement convexe si et seulement si A est une matrice définie positive.

2.3 Critère de convexité pour J

Déduisons des questions précédentes un critère de convexité pour J et un critère de stricte convexité.

On a :

$$J(x) = \frac{1}{2}f(x) - \langle b, x \rangle$$

On sait déjà que f est convexe/strictement convexe si et seulement si A est une matrice semi définie positive/définie positive. Puisque la somme de fonctions convexe est aussi convexe, il nous suffit de déterminer si oui ou non $\langle b, x \rangle$ l'est.

Notons $g(x) = \langle b, x \rangle$.

On a :

$$g(\lambda x + (1 - \lambda)y) = \langle b, \lambda x + (1 - \lambda)y \rangle$$

$$\Leftrightarrow \lambda \langle b, x \rangle + (1 - \lambda) \langle b, y \rangle \Leftrightarrow \lambda g(x) + (1 - \lambda)g(y)$$

Ainsi, g est linéaire, donc forcément convexe. Comme vu à la question 1, le fait que g soit strictement convexe implique que la convexité de J est la même que celle de f .

Ainsi, comme pour f , J est convexe si et seulement si A est une matrice semi définie positive et est strictement convexe si et seulement si A est une matrice définie positive.

2.4 Minimum global

On supposera à présent et dans les questions suivantes que J est une fonction quadratique convexe.

Nous allons montrer que si J admet un minimum local en x alors c'est un minimum global.

Définition minimum local :

Etre un minimum local signifie qu'il existe $R > 0$ tel que :

$$J(x) = \min\{J(z) \mid \forall z \in E, \|z - x\| \leq R\}$$

Nous allons raisonner par l'absurde. Montrons que s'il existe un y tel que $\|y - x\| > R$ et $J(y) < J(x)$, on peut trouver un z de la forme :

$$z = (1 - \theta)x + \theta y$$

pour un $\theta \in [0, 1]$ bien choisi tel que :

$$\|z - x\| \leq R \quad \text{et} \quad J(z) < J(x)$$

On suppose qu'il existe y tel que $\|y - x\| > R$ et $J(y) < J(x)$, soit qu'il existe un y en-dehors de la boule de rayon R considérée tel que x n'est pas un minimum global.

On a :

$$z - x = (1 - \theta)x + \theta y - x = \theta(y - x)$$

Donc :

$$\|z - x\| \leq R \iff \theta \leq \frac{R}{\|y - x\|}$$

On prend donc $\theta = \frac{R}{\|y-x\|}$ pour respecter cette condition.

$R > 0$ et $\|y - x\| > 0$ donc $\theta > 0$ et $\|y - x\| > R$ d'après l'hypothèse initiale, donc $\theta \leq 1$.

Ainsi, on a bien $\theta \in [0, 1]$.

D'après la définition de la convexité :

$$J(z) \leq (1 - \theta)J(x) + \theta J(y)$$

Or, d'après l'hypothèse initiale, $J(y) < J(x)$, donc :

$$(1 - \theta)J(x) + \theta J(y) < (1 - \theta)J(x) + \theta J(x) = J(x)$$

Ainsi :

$$\boxed{J(z) < J(x)}$$

Cependant, cela implique qu'il existe un z tel que x n'est pas un minimum local. Donc il n'existe aucun y en-dehors de la boule de rayon R tel que $J(y) < J(x)$. Autrement dit, si x est un minimum local, x est aussi un minimum global.

2.5 Dérivée directionnelle de J en x dans la direction h

Fixons $h \in E$, trouvons pour tout $x \in E$, l'expression de la dérivée directionnelle de J en x dans la direction h .

On appellera gradient de J la fonction notée ∇J et définie pour tout $x \in E$ par :

$$\nabla J(x) := A(x) - b$$

On a :

$$\begin{aligned} D_h J(x) &= \lim_{\varepsilon \rightarrow 0} \frac{J(x + \varepsilon h) - J(x)}{\varepsilon} \\ &= \lim_{\varepsilon \rightarrow 0} \frac{\frac{1}{2} \langle x + \varepsilon h, A(x + \varepsilon h) \rangle - \langle b, x + \varepsilon h \rangle - \frac{1}{2} \langle x, A(x) \rangle + \langle b, x \rangle}{\varepsilon} \\ &= \lim_{\varepsilon \rightarrow 0} \frac{\frac{1}{2} \langle x, A(\varepsilon h) \rangle + \frac{1}{2} \langle \varepsilon h, A(x + \varepsilon h) \rangle - \langle b, \varepsilon h \rangle}{\varepsilon} \\ &= \lim_{\varepsilon \rightarrow 0} \left(\frac{1}{2} \langle x, A(h) \rangle + \frac{1}{2} \langle h, A(x + \varepsilon h) \rangle - \langle b, h \rangle \right) \\ &= \frac{1}{2} \langle x, A(h) \rangle + \frac{1}{2} \langle h, A(x) \rangle - \langle b, h \rangle \end{aligned}$$

D'après l'énoncé, puisque A est une application symétrique :

$$\langle x, A(h) \rangle = \langle A(x), h \rangle = \langle h, A(x) \rangle$$

,donc :

$$\boxed{D_h J(x) = \langle h, A(x) \rangle - \langle b, h \rangle = \langle h, A(x) - b \rangle}$$

2.6 Critères de convexité de J

Montrons que J est convexe si et seulement si pour tout $(x, y) \in E \times E$:

$$J(y) \geq J(x) + \langle y - x, \nabla J(x) \rangle$$

Supposons que $J(x)$ est convexe et démontrons $J(y) \geq J(x) + \langle y - x, \nabla J(x) \rangle$.

On a :

$$J((1 - \theta)x + \theta y) \leq (1 - \theta)J(x) + \theta J(y).$$

$$\iff \frac{J(x - \theta x + \theta y) - (1 - \theta)J(x)}{\theta} \leq J(y) \text{ avec } \theta \neq 0$$

$$\Longleftrightarrow \frac{J(x + \theta(y - x)) - J(x)}{\theta} + J(x) \leq J(y) \text{ avec } \theta \neq 0$$

On trouve :

$$\lim_{\theta \rightarrow 0^+} \frac{J(x + \theta(y - x)) - J(x)}{\theta} + J(x) = D_{y-x}J(x) + J(x) \leq J(y)$$

D'où :

$$J(x) + \langle y - x, \nabla J(x) \rangle \leq J(y)$$

Nous avons démontré la première implication :

$$\boxed{J((1 - \theta)x + \theta y) \leq (1 - \theta)J(x) + \theta J(y) \implies J(x) + \langle y - x, \nabla J(x) \rangle \leq J(y)}$$

Supposons maintenant $J(x) + \langle y - x, \nabla J(x) \rangle \leq J(y)$ et démontrons que $J(x)$ est convexe.

Prenons :

$$J(\theta y + (1 - \theta)x) = J(x + \theta(y - x))$$

On applique un développement de Taylor à l'ordre 1 :

$$J(x) + \theta \nabla^T J(x)(y - x) + \theta(y - x)$$

Avec :

$$\nabla^T J(x)(y - x) = \langle y - x, \nabla J(x) \rangle$$

Ainsi, d'après notre supposition :

$$J(x) + \theta \langle y - x, \nabla J(x) \rangle + \theta(y - x) \leq J(x) + \theta(J(y) - J(x)) = \theta J(y) + (1 - \theta)J(x)$$

On trouve donc bien :

$$J(\theta y + (1 - \theta)x) \leq \theta J(y) + (1 - \theta)J(x)$$

Ainsi :

$$\boxed{J(x) + \langle y - x, \nabla J(x) \rangle \leq J(y) \implies J((1 - \theta)x + \theta y) \leq (1 - \theta)J(x) + \theta J(y)}$$

On peut donc conclure que :

$$\boxed{J((1 - \theta)x + \theta y) \leq (1 - \theta)J(x) + \theta J(y) \iff J(x) + \langle y - x, \nabla J(x) \rangle \leq J(y)}$$

2.7 Minimum global x de J avec $\nabla J(x) = 0$.

Déduisons de la question précédente que x est minimum global pour J si et seulement si : $\nabla J(x) = 0$.

Supposons $\nabla J(x) = 0$, d'après la question précédente, on a pour tout $x, y \in E^2$ si J est convexe :

$$\begin{aligned} J(y) &\geq J(x) + \langle y - x, \nabla J(x) \rangle \\ \iff J(y) &\geq J(x) + \langle y - x, 0 \rangle = J(x) \end{aligned}$$

On a démontré la première implication.

Supposons maintenant que $\forall x, y \in E^2, J(y) \geq J(x)$, donc que x est un minimum global. Si x est un minimum global, il est nécessairement aussi un point critique de $J : \nabla J(x) = 0$.

Ainsi :

$$\boxed{\forall x, y \in E^2, \nabla J(x) = 0 \iff J(y) \geq J(x)}$$

2.8 Version générale de l'algorithme du gradient conjugué

On a, $J(x) = \frac{1}{2}\langle x, A(x) \rangle - \langle b, x \rangle$, on cherche un algorithme qui fait tendre x_k vers la solution exacte x^* de $Ax = b$: dans un espace vectoriel de dimension fini E muni d'un produit scalaire $\langle \cdot, \cdot \rangle$ et pour une fonction J quadratique convexe.

Initiation : On prend $x_0 \in \mathbb{R}$ quelconque. On pose $r_k = b - Ax_k$, le résidu d'indice k et p la direction de descente. Pour $k = 0$, on a :

$$r_0 = b - Ax_0, p_0 = r_0, k = 0$$

Récurrence : Tant que $\|r_k\| > \varepsilon$, notre critère d'arrêt, on effectue les opérations suivantes de manière itérative :

$$\alpha_k = \frac{\langle r_k, p_k \rangle}{\langle Ap_k, p_k \rangle}$$

$$x_{k+1} = x_k + \alpha_k p_k$$

$$r_{k+1} = b - Ax_{k+1}$$

$$\beta_k = \frac{\langle Ar_{k+1}, p_k \rangle}{\langle p_k, Ap_k \rangle}$$

$$\beta_k = \frac{\langle Ar_{k+1}, p_k \rangle}{\langle p_k, Ap_k \rangle}$$

$$p_{k+1} = r_{k+1} - \beta_k p_k$$

$$k \leftarrow k + 1$$

Finalisation : On prend le premier x_k tel que $\|r_k\| \leq \varepsilon$ comme solution approximative.

2.9 Ecart théorique entre deux itérés

En notant $(x_{(k)})_{k \in \mathbb{N}}$ la suite des itérés de l'algorithme du gradient conjugué précédent donnons une expression pour un $k \in \mathbb{N}$ de l'écart théorique entre deux itérés :

$$e_{(k)} := J(x_{(k+1)}) - J(x_{(k)})$$

On a, avec $x_{k+1} - x_k = \alpha_k p_k$:

$$J(x_{k+1}) - J(x_k) = \frac{1}{2} \langle x_{k+1} - x_k, A(x_{k+1} - x_k) \rangle - \langle b, x_{k+1} - x_k \rangle$$

$$= \frac{1}{2} \alpha_k^2 \langle p_k, A(p_k) \rangle - \alpha_k \langle b, p_k \rangle$$

2.10 Python de l'algorithme du gradient conjugué de la question précédente

```

1 def grad_conj_ps(x0, P, Q, b, i, epsilon, itermax):
2
3     def A(X, P, Q):
4         return P @ X + X @ Q
5
6     def ps(A,B,i=1):
7         if i == 0: return A.T @ B
8         elif i == 1: return np.trace(A.T @ B)
9
10    #---Initialisation---
11
12    k=0 #initialisation de k
13    g = A(x0, P, Q) - b #gradient de x0 en fonction de A
14    d = -g #direction
15
16    #---Recurrence---
17    while (np.linalg.norm(g)>epsilon) and k<itermax:
18        beta = ps(g, d, i)/ps(d, A(d, P, Q), i) #calcul du taux d'apprentissage
19        x = x0 - beta*d #calcul de x(k) partir de x(k-1)
20        x0 = x #definition du nouveau x
21        g = A(x, P, Q) - b #calcul du nouveau gradient pour x(k)
22        beta = ps(A(g, P, Q), d, i)/ps(d, A(d, P, Q), i)
23        d = -g + beta*d #redefinition de la nouvelle direction
24        k+=1
25    return x, k

```

Listing 1: Fonction Python de l'algorithme du gradient conjugué

2.11 Application

Nous allons nous intéresser à un cas particulier de l'équation de Sylvester. On retrouve cette équation dans de nombreux problèmes (du traitement d'image à l'étude de systèmes dynamiques linéaires, etc...).

Application des équations de Sylvester :

L'équation de Sylvester, qui porte le nom du mathématicien britannique **James Joseph Sylvester (1814-1897)**, est une équation matricielle fondamentale en algèbre linéaire. Sylvester est connu pour ses contributions majeures à l'algèbre, notamment dans les domaines des invariants, des matrices et des formes quadratiques. L'équation qui porte son nom trouve une large application dans les sciences de l'ingénierie et de la modélisation, en particulier dans des disciplines nécessitant l'analyse et le contrôle des systèmes dynamiques, Applications en traitement du signal ainsi que pour le traitement d'images, Compression d'images, Analyse de textures et segmentation, Correspondance d'images et alignement, Colorisation automatique et transfert de style.




Figure 3: Portrait de James Joseph Sylvester (1814-1897)

Soient P , Q et R des matrices de tailles respectives (m, m) , (n, n) et (m, n) et l'on cherche $X \in \mathcal{M}_{m,n}(\mathbb{R})$ tel que :

$$(S) \quad PX + XQ = R$$

En reprenant les notations de cette partie, on pose : $E = \mathcal{M}_{m,n}(\mathbb{R})$, $\langle \cdot, \cdot \rangle = \text{Trace}(\cdot^T \cdot)$, $A(X) := PX + XQ$ et :

$$J(X) := \frac{1}{2} \langle X, A(X) \rangle - \langle R, X \rangle$$

2.11.1 J une fonction quadratique sur $(E, \langle \cdot, \cdot \rangle)$.

On a $J(X) = \frac{1}{2}\langle X, A(X) \rangle - \langle R, X \rangle$

Le terme $\langle R, X \rangle$ est linéaire en X , il suffit donc de montrer que A est une application linéaire symétrique pour montrer que J est une forme quadratique.

Soient $X, Y \in E$ et $\lambda \in \mathbb{R}$, on a :

$$\begin{aligned} A(X + \lambda Y) &= P(X + \lambda Y) + (X + \lambda Y)Q \\ &= PX + \lambda PY + XQ + \lambda YQ \\ &= A(X) + \lambda A(Y) \end{aligned}$$

Donc A est bien linéaire.

De plus, sachant que la trace est linéaire symétrique, on a :

$$\text{Tr}(A^T B) = \text{Tr}(B^T A), \text{Tr}(AB) = \text{Tr}(BA).$$

On suppose également que P et Q sont symétriques. Donc :

$$\begin{aligned} \langle X, A(Y) \rangle &= \text{Tr}(X^T A(Y)) = \text{Tr}(X^T (PY + YQ)) = \text{Tr}(X^T PY) + \text{Tr}(X^T YQ) \\ &= \text{Tr}(X^T P^T Y) + \text{Tr}(X^T YQ^T) = \text{Tr}(Y^T PX) + \text{Tr}(YQ^T X^T) \\ &= \text{Tr}(Y^T PX) + \text{Tr}(XQY^T) = \text{Tr}(Y^T (PX + XQ)) = \text{Tr}(Y^T A(X)) = \text{Tr}(A(X)^T Y) \\ &= \langle A(X), Y \rangle \end{aligned}$$

Ainsi, sous la condition que P et Q soient symétriques, J est une forme quadratique.

2.11.2 Minimum de J

Pour P et Q des matrices symétriques semi-définies positives, J est une forme quadratique mais également convexe. Puisque J est convexe, elle admet un minimum global. Celui-ci est non nécessairement unique car P et Q sont seulement semi-définies et non définies donc J est convexe non strict.

2.11.3 Les minimas de J et l'équation de Sylvester (S)

Les minimas de J s'exprime alors de la façon suivante, avec $\frac{\partial}{\partial X} \text{Tr}(AXB) = AB^T$:

$$\begin{aligned} \frac{\partial J}{\partial X} &= 0 \\ \iff \frac{\partial}{\partial X} \left(\frac{1}{2} \langle X, A(X) \rangle - \langle R, X \rangle \right) &= \frac{1}{2} \frac{\partial}{\partial X} (\text{Tr}(X^T A(X))) - R = 0 \\ \iff \frac{1}{2} \frac{\partial}{\partial X} (\text{Tr}(X^T PX) + \text{Tr}(X^T XQ)) - R &= \frac{1}{2} \frac{\partial}{\partial X} (\text{Tr}(X^T PX) + \text{Tr}(XQX^T)) - R = 0 \\ \iff \frac{1}{2} (PX + PX^T + XQ + X^T Q) - R &= \frac{1}{2} (2PX + 2XQ) - R = PX + XQ - R = 0 \\ \iff PX + XQ &= R \end{aligned}$$

On retrouve bien l'équation de Sylvester.

2.11.4 Test de algorithme

Maintenant nous allons tester notre algorithme avec les matrices :

$$P = Q := \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}, \quad R := 0_{2,2}$$

- **Calcul à la main :**

Soit $P = Q = \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}$, $x = \begin{pmatrix} x_1 & x_2 \\ x_3 & x_4 \end{pmatrix}$. On pose :

$$PX + XQ = R = 0_{2 \times 2}.$$

Ceci s'écrit :

$$\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} \begin{pmatrix} x_1 & x_2 \\ x_3 & x_4 \end{pmatrix} + \begin{pmatrix} x_1 & x_2 \\ x_3 & x_4 \end{pmatrix} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

En développant les produits matriciels, on obtient :

$$\begin{pmatrix} 4x_1 + x_2 + x_3 & x_1 + 4x_2 + 0 + x_4 \\ x_1 + 0 + 4x_3 + x_4 & 0 + x_2 + x_3 + 4x_4 \end{pmatrix} = \begin{pmatrix} 0 & 0 \\ 0 & 0 \end{pmatrix}.$$

On en déduit le système suivant :

$$\begin{cases} 4x_1 + x_2 + x_3 = 0, \\ x_1 + 4x_2 + x_4 = 0, \\ x_1 + 4x_3 + x_4 = 0, \\ x_2 + x_3 + 4x_4 = 0. \end{cases}$$

Ce système équivaut à :

$$\begin{cases} x_1 = 0, \\ x_2 = 0, \\ x_3 = 0, \\ x_4 = 0. \end{cases}$$

- **Résultat de l'algorithme :**

Comme vu précédemment, à la main, on trouve que X est nulle car R l'est. En utilisant l'algorithme du gradient conjugué de la question 10, on trouve que le code suivant renvoie également une matrice de taille 2×2 proche de 0 :

$$\begin{bmatrix} 0.66666667 & 0.33333333 \\ 0.66666667 & 0.33333333 \end{bmatrix}$$

- **Conclusion**

Avec le code, on obtient pas directement une matrice nulle. On obtient une matrice avec des termes négligeables si x_0 n'est pas déjà une matrice nulle.

3 En mélangeant tout ça...

Dans cette partie nous allons appliquer les résultats des deux parties précédentes en utilisant des variations autour de l'équation de Poisson.

Qui était Siméon Denis Poisson ?

L'équation de Poisson vient du mathématicien français **Siméon Denis Poisson (1781–1842)** était un mathématicien et physicien français, célèbre pour ses contributions en analyse mathématique, en mécanique, et en théorie des probabilités. Ses travaux ont influencé de nombreux domaines scientifiques, et il est notamment connu pour ses recherches sur les équations différentielles et les lois physiques. L'équation de Poisson est une pièce maîtresse pour décrire des phénomènes physiques où une quantité diffuse ou se répartit sous l'influence d'une source ou des charges électriques.



Figure 4: Portrait de Siméon Denis Poisson (1781–1842)

3.1 Un problème d'électrostatique

Soit $\Omega \subset]0, L_1[\times]0, L_2[\subset \mathbb{R}^2$, on s'intéresse au potentiel électrostatique V sur Ω en fonction d'une densité surfacique de charge ρ . **On supposera que V est nul sur $\partial\Omega$** , i.e. que le potentiel électrostatique est nul « loin » de la répartition des charges. En notant classiquement ϵ_0 la permittivité du vide, nous supposons que le potentiel électrostatique est un point critique de l'action suivante :

$$S(V) := \iint_{\Omega} \left(\frac{1}{2} \|\nabla V(x, y)\|_2^2 - \frac{1}{\epsilon_0} \rho(x, y) V(x, y) \right) dx dy.$$

3.1.1 Équation vérifiée par un point critique de S

On a démontré dans la partie 1.3 qu'un point critique devait vérifier l'équation d'Euler-Lagrange suivante :

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \frac{\partial L}{\partial (\partial_x u)} + \frac{d}{dy} \frac{\partial L}{\partial (\partial_y u)}.$$

Nous allons appliquer cette condition à la fonction intégrée dans S . Tout d'abord, pour l'expression de gauche, en dérivant par rapport à V , il vient simplement :

$$\frac{\partial L}{\partial u} = -\frac{1}{\epsilon_0} \rho(x, y).$$

Pour la partie de droite :

$$\frac{d}{dx} \left(\frac{\partial L}{\partial (\partial_x V)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial (\partial_y V)} \right) = \frac{d}{dx} \left(\frac{\frac{\partial}{\partial x} \|\nabla V(x, y)\|_2^2}{\partial (\partial_x V)} \right) + \frac{d}{dy} \left(\frac{\frac{\partial}{\partial y} \|\nabla V(x, y)\|_2^2}{\partial (\partial_y V)} \right).$$

Cela nous donne :

$$\frac{d}{dx} \left(\frac{\partial}{\partial x} V \right) + \frac{d}{dy} \left(\frac{\partial}{\partial y} V \right) = \Delta V(x, y).$$

Finalement, en égalant les deux expressions, on obtient l'équation suivante vérifiant les points critiques de S :

$$\Delta V(x, y) = -\frac{1}{\epsilon_0} \rho(x, y).$$

Discretisation du problème

Nous allons discrétiser le problème précédent. On fixe M et N deux entiers non nuls et on pose la discrétisation suivante :

$$\Delta x := \frac{L}{M+1}, \quad \Delta y := \frac{L}{N+1},$$

$$x_i := i\Delta x, i \in \{0, 1, \dots, M+1\}, \quad y_j := j\Delta y, j \in \{0, 1, \dots, N+1\}.$$

Comme V est nul sur $\partial\Omega$, on supposera que :

$$\begin{cases} V(0, y) = V(L_1, y) = 0 & \forall y \in \Omega, \\ V(x, 0) = V(x, L_2) = 0 & \forall x \in \Omega. \end{cases}$$

Cela nous permettra d'identifier le potentiel recherché V sur une matrice $M \times N$ ($\mathbb{R}$) dont les coefficients sont donnés par

$$\mathbf{V}_{i,j} := \mathbf{V}(\mathbf{x}_i, \mathbf{y}_j)$$

Développons le membre de gauche grâce aux développements de Taylor à l'ordre 3 par rapport à x_i et y_j . Ce qui nous donne les approximations suivantes :

$$\begin{cases} V(x_{i+1,j}) = V(x_{i,j} + h) = V(x_{i,j}) + V'(x_{i,j})h + V''(x_{i,j})h^2 + V'''(x_{i,j})h^3 + \mathcal{O}(h^4), \\ V(x_{i-1,j}) = V(x_{i,j} - h) = V(x_{i,j}) - V'(x_{i,j})h + \frac{1}{2}V''(x_{i,j})h^2 - \frac{1}{3!}V'''(x_{i,j})h^3 + \mathcal{O}(h^4). \end{cases}$$

En sommant les deux expressions, on obtient l'approximation $V(x_i)$ grâce aux développements de Taylor que l'on vient de réaliser. Et on peut finalement poser :

$$V''(x_{i,j}) = \frac{V(x_{i+1,j}) - 2V(x_{i,j}) + V(x_{i-1,j}))}{h^2} + \mathcal{O}(h^2).$$

Appliquons la même méthode par rapport à y . En remplaçant les résultats obtenus dans l'équation de la partie précédente, on a, pour tout $(i, j) \in [1, M] \times [1, N]$:

$$\left(\frac{V_{i+1,j} - 2V_{i,j} + V_{i-1,j}}{(\Delta x)^2} \right) + \left(\frac{V_{i,j+1} - 2V_{i,j} + V_{i,j-1}}{(\Delta y)^2} \right) = -\frac{1}{\epsilon_0} \rho(x_i, y_j).$$

Application Numérique

Dans cette partie, nous allons créer un code Python qui va résoudre e_{ij} à l'aide du gradient conjugué fait précédemment dans la partie 2. Pour simplifier les applications numériques, il sera admis que $\Delta x = \Delta y = 1$ et $\epsilon_0 = 1$. On prendra la matrice R du fichier **R.npy** de taille (512,512) qui représente deux plaques d'un condensateur. On commence par définir une fonction pour créer les matrices LM et LN :

```

1 def L(M):
2     # Cree une matrice carree de dimensions M x M remplie de zeros
3     LM = np.zeros((M, M))
4
5     for i in range(M):
6         LM[i, i] = -2 # Remplit la diagonale principale avec -2
7         if i < M - 1:
8             LM[i, i+1] = 1 # Remplit la diagonale au-dessus avec 1
9         if i > 0:
10            LM[i, i-1] = 1 # Remplit la diagonale en-dessous avec 1
11    return LM

```

Listing 2: Création des matrices LM et LN

Après cela, on résout grâce au gradient conjugué précédemment en utilisant les nouveaux R , LM et LN pour calculer V , le potentiel électrique. Le potentiel est représenté ainsi : On rappelle l'expression de $\mathbf{E}$, le champ électrique en fonction de V , le potentiel électrostatique (calculé avec le gradient conjugué précédent) :

$$\mathbf{E} = -\nabla V$$

Ainsi, on peut approximer les dérivées partielles à l'ordre 2 de V avec le problème suivant avec (x_m, y_n) où m et n sont les dimensions de R , définie aussi pour LM et LN :

$$E_{m,n} = \left(\frac{\partial V}{\partial x}(x_m, y_n), \frac{\partial V}{\partial y}(x_m, y_n) \right)$$




Figure 5: Représentation du potentiel électrique

On utilise la formule de **Taylor** à l'ordre 2 et ainsi :

$$V(x+h, y) = V(x) + \frac{\partial V(x, y)}{\partial x} h + \frac{\partial^2 V(x, y)}{\partial x^2} \frac{h^2}{2} + o(\|h^3\|)$$

$$V(x-h, y) = V(x) - \frac{\partial V(x, y)}{\partial x} h + \frac{\partial^2 V(x, y)}{\partial x^2} \frac{h^2}{2} + o(\|h^3\|)$$

En soustrayant ces deux expressions, et en prenant en compte que $\Delta_x = \Delta_y = 1$, on obtient ainsi :

$$2\Delta x \frac{\partial V}{\partial x}(x_m, y_n) = V(x_{m+1}, y_n) - V(x_{m-1}, y_n)$$

De même :

$$\frac{\partial V}{\partial y}(x_m, y_n) = \frac{V(x_m, y_{n+1}) - V(x_m, y_{n-1})}{2\Delta y}$$

Ces deux matrices carrées D_M et D_N nous donnent finalement $\mathbf{E} \approx (D_M V, V D_N^T)$.

Ces deux matrices de tailles M et N sont de la forme :

$$D = \begin{bmatrix} 0 & 0.5 & \cdots & 0 & 0 \\ -0.5 & 0 & \cdots & 0 & 0 \\ \vdots & & \ddots & & \vdots \\ 0 & 0 & \cdots & 0 & 0.5 \\ 0 & 0 & \cdots & -0.5 & 0 \end{bmatrix}$$

Si les variations de V sur x et y sont de l'ordre de Δ_x et Δ_y , l'approximation est valable, de plus E est nul sur $\partial\Omega$ donc que loin des charges E est nul.

Pour calculer E en Python, on utilise le code suivant :

```

1 def champs_electriques(V):
2     # Calcule des derivees pour obtenir les champs electriques Ex et Ey
3     Ey = -0.5 * (np.roll(V, -1, axis=0) - np.roll(V, 1, axis=0)) # Derivee selon y
4     Ex = -0.5 * (np.roll(V, -1, axis=1) - np.roll(V, 1, axis=1)) # Derivee selon x
5     return Ex, Ey

```

Listing 3: Calcul des champs électriques Ex et Ey

On teste avec **R.npy** pour confirmer les résultats. Le tout en utilisant la commande **contourf** pour les lignes de niveau et la commande **streamplot** pour les lignes de champ. On a ainsi avec une matrice qui est simplement **R.npy** avec les charges inversées :




Figure 6: Représentation du champ électrique et du potentiel electro-statique

Pour cette partie on reprend les fonctions créer pour calculer et dessiner les lignes de champ. L'objectif est de créer une matrice R en dessinant les charges positives et négatives. Les charges négatives sont représenté par un -1 et positives pour un +1 et ainsi en appliquant les fonctions précédentes à celui-ci on trouve les lignes de champs. Voici ainsi représenté un H avec des pôles négatifs et positifs :




Figure 7: Représentation du champ électrique et du potentiel electro-statique

Pour aller plus loin : Les calculs matriciels étant très lourds, le gradient conjugué peut être optimisé en multithreading afin d'accélérer le processus. Les processeurs modernes possédant plusieurs cœurs, il est possible d'exécuter plusieurs tâches en parallèle pour améliorer les performances.

Source : <https://www.geeksforgeeks.org/multithreading-python-set-1/>




Figure 8: Représentation du multithreading et du single-thread.

3.2 De l'interpolation guidé avec l'équation de Poisson.

Dans cette partie, nous allons nous placer sur des matrices incarnant des images. Nous reprendrons en partie les notations des sections précédentes. Afin de simplifier l'exposition, nous nous placerons dans le cas d'une matrice, c'est-à-dire d'une image en noir et blanc, le cas de la couleur revenant à refaire les calculs sur les trois couches de l'image. Le but de cette partie est de réaliser de l'édition d'image. Nous allons essayer de modifier une image en utilisant le contenu d'une autre image et/ou plus généralement un "champ de vecteurs" donné à l'avance.

Avant de travailler sur la matrice/image directement, nous devons faire un détour par une étape de formalisation de notre problème. Dans cette partie, nous allons considérer des images U et F comme des fonctions à deux variables réelles définies sur le rectangle.

$]0, m + 1[\times]0, n + 1[$ à valeurs dans $\mathbb{R}$ Dans toute cette partie, on supposera que les fonctions intervenantes sont de classe C^2 et que F représente l'image à modifier.

Soit $\Omega \subset]0, m + 1[\times]0, n + 1[$ un fermé connexe (c'est-à-dire d'un seul tenant) et notons $\partial\Omega$ la frontière (c'est-à-dire le bord) de Ω . Moralement, on considérera l'intérieur de Ω noté $\Omega = \frac{\Omega}{\partial\Omega}$ comme un ensemble de pixels à conserver. Le but est donc de trouver une fonction de classe $C^2 : u :]0, m + 1[\times]0, n + 1[\rightarrow \mathbb{R}$ vérifiant certains critères, critères que nous développerons dans la suite, telle que la restriction de u au bord de $\partial\Omega$ soit égale à une fonction f fixée sur ce même bord. La fonction f sur $\partial\Omega$ représente les pixels à conserver. On note cela :

$$u|_{\partial\Omega} = f|_{\partial\Omega}$$

Afin de traiter ce problème, nous allons choisir comme critère de complétion/d'interpolation pour la fonction u que les variations (c'est-à-dire le gradient) de l'image à modifier doivent suivre un champ de vecteurs donné dans Ω tout en conservant les pixels donnés par f sur le bord.

Mathématiquement, nous allons chercher u telle que l'action suivante soit minimale sur Ω :

$$S(u) := \frac{1}{2} \iint_{\Omega} \|\nabla u(x, y) - g(x, y)\|_2^2 dx dy$$

Où le $\frac{1}{2}$ et la norme au carré ont été rajoutés pour faciliter les calculs, et $g : (g_x, g_y) : \mathbb{R}^2 \rightarrow \mathbb{R}^2$ est un champ de vecteurs de $\mathbb{R}^2$

3.2.1 Equation vérifiée par un point critique de S.

On pose tout d'abord le Langragien de l'action $S(u)$:

$$L(u, \partial_x u, \partial_y u, x, y) := \frac{1}{2} \|\nabla u(x, y) - g(x, y)\|_2^2$$

Nous avons vu dans la partie 1 que $\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right)$

On peut réécrire cela de façon suivante :

$$\frac{\partial L}{\partial(\partial_x u)} = \frac{\partial}{\partial(\partial_x u)} \left(\frac{1}{2} \|\nabla u(x, y) - g(x, y)\|_2^2 \right)$$

$$\frac{\partial L}{\partial(\partial_x u)} = \frac{1}{2} \frac{\partial}{\partial(\partial_x u)} \left(\left(\frac{\partial u}{\partial x} - g_x \right)^2 + \left(\frac{\partial u}{\partial y} - g_y \right)^2 \right)$$

Cela nous permet d'obtenir :

$$\begin{cases} \frac{\partial L}{\partial(\partial_x u)} = \partial_x u - g_x, \\ \frac{\partial L}{\partial(\partial_y u)} = \partial_y u - g_y, \\ \frac{\partial L}{\partial u} = 0. \end{cases}$$

D'après l'équation d'Euler-Lagrange pour plusieurs variables, les points critiques de S vérifient :

$$\frac{\partial L}{\partial u} = \frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) + \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right)$$

avec :

$$\begin{cases} \frac{d}{dx} \left(\frac{\partial L}{\partial(\partial_x u)} \right) = \frac{\partial(\partial_x u)}{\partial x} - \frac{\partial g_x}{\partial x}, \\ \frac{d}{dy} \left(\frac{\partial L}{\partial(\partial_y u)} \right) = \frac{\partial(\partial_y u)}{\partial y} - \frac{\partial g_y}{\partial y}. \end{cases}$$

d'où :

$$\begin{aligned} \frac{\partial(\partial_x u)}{\partial x} - \frac{\partial g_x}{\partial x} &= \frac{\partial(\partial_y u)}{\partial y} - \frac{\partial g_y}{\partial y} \\ \Leftrightarrow \frac{\partial(\partial_x u)}{\partial x} + \frac{\partial(\partial_y u)}{\partial y} &= \frac{\partial g_x}{\partial x} + \frac{\partial g_y}{\partial y} \\ \boxed{\Leftrightarrow \Delta u = \operatorname{div}(g)} \end{aligned}$$

On obtient donc bien le problème :

$$(L) \quad \begin{cases} \Delta u = \operatorname{div}(g) & \text{à l'intérieur de } \Omega, \\ u = f & \text{sur } \partial\Omega. \end{cases}$$

Les matrices masquées : Justifions d'abord que E , l'espace des matrices masquées par le masque M :

$$E := \{A \in M_{m,n}(\mathbb{R}) \mid A = A * M\},$$

où $(*)$ correspond au produit d'Hadamard, est bien un espace vectoriel.

Petit point d'intérêt sur le produit de Hadamard:

Le produit de Hadamard est une opération utilisée principalement en algèbre linéaire, qui consiste à effectuer une multiplication élément par élément entre deux matrices de même taille. Soient A et B deux matrices de dimensions identiques $m \times n$ avec des éléments respectifs $a_{i,j}$ et $b_{i,j}$. Alors, il existe une matrice $A \circ B = C$, appelée produit de Hadamard, telle que chaque élément $c_{i,j}$ est défini par :

$$c_{i,j} = a_{i,j} \cdot b_{i,j}, \quad \text{pour tous } 1 \leq i \leq m \text{ et } 1 \leq j \leq n$$

Cette opération porte le nom du mathématicien français **Jacques Hadamard (1865–1963)**, connu pour ses contributions à l'analyse, à la théorie des nombres et à la mécanique. Il est notamment célèbre pour ses travaux sur les équations aux dérivées partielles, la détermination des nombres premiers, ainsi que pour des concepts comme les matrices de Hadamard.



Figure 9: Portrait de Jacques Hadamard (1865–1963)

Il suffit de montrer différentes propriétés :

1. Élément neutre : Soit $0_{m,n}$ la matrice nulle de taille (m, n) . On a bien $M, 0_{m,n} * M = 0_{m,n}$. L'élément neutre appartient donc bien à E .

2. Justification de E comme espace vectoriel :

(a) Additivité : Soit $(A, B) \in E \times E$; on a donc :

$$A + B = (A * M) + (B * M) = (A + B) * M.$$

Donc $(A + B) \in E$.

(b) Homogénéité : On pose $A \in E$ et $\lambda \in \mathbb{R}$. On a :

$$\lambda A = \lambda \cdot (A * M) = (\lambda \cdot A) * M.$$

Donc $(\lambda A) \in E$.

On peut donc affirmer que E est un espace vectoriel.

Montrons maintenant que

$$\langle \cdot, \cdot \rangle = \text{Trace}(\cdot^T \cdot)$$

est un produit scalaire.

1. **Symétrie** : Soit $(A, B) \in E^2$. On a :

$$\langle A, B \rangle = \text{Trace}(A^T B).$$

D'après les propriétés de la trace, on a :

$$\text{Trace}(A^T B) = \text{Trace}(B^T A) = \langle B, A \rangle.$$

Donc $\langle \cdot, \cdot \rangle = \text{Trace}(\cdot^T \cdot)$ est bien symétrique.

2. **Bilinéarité** : Soit $(A, B, C) \in E^3$ et $(\lambda, \mu) \in \mathbb{R}^2$. On a :

$$\langle \lambda A + \mu B, C \rangle = \text{Trace}((\lambda A + \mu B)^T C).$$

Par propriété de la trace :

$$\text{Trace}((\lambda A + \mu B)^T C) = \lambda \cdot \text{Trace}(A^T C) + \mu \cdot \text{Trace}(B^T C) = \lambda \cdot \langle A, C \rangle + \mu \cdot \langle B, C \rangle.$$

Donc $\langle \cdot, \cdot \rangle$ est bien linéaire à gauche. Étant donné que $\langle \cdot, \cdot \rangle$ est symétrique, elle est également linéaire à droite. Cette application est donc bien bilinéaire.

3. **Définie positive** : Soit $A \in E$. On a assez clairement $\langle A, A \rangle \geq 0$, et $\langle A, A \rangle = 0 \implies A = 0_{m,n}$. Donc $\langle \cdot, \cdot \rangle$ est bien définie positive.

Ainsi, on a montré que E est bien un espace vectoriel muni d'un produit scalaire $\langle \cdot, \cdot \rangle = \text{Trace}(\cdot^T \cdot)$.

On considérera le pas de discrétisation $h = \Delta x = \Delta y = 1$ pour les images, en effet pour une image l'élément de longueur le plus petit possible est le passage d'un pixel à un autre i.e d'un entier à un autre. On sait que :

$$\frac{\partial^2 f}{\partial x^2}(x_i) \approx \frac{f_{i-1} - 2f_i + f_{i+1}}{h}.$$

On peut dès lors réécrire l'approximation à l'ordre 2 du problème (L) : Avec $h = 1$ et $f = U$:

$$\begin{cases} \frac{\partial U}{\partial x} \approx \frac{1}{2}(U_{i-1,j} - U_{i+1,j}), \\ \frac{\partial U}{\partial y} \approx \frac{1}{2}(U_{i,j-1} - U_{i,j+1}). \end{cases}$$

$$\begin{cases} \frac{\partial^2 U}{\partial x^2} \approx U_{i-1,j} - 2 \cdot U_{i,j} + U_{i+1,j}, \\ \frac{\partial^2 U}{\partial y^2} \approx U_{i,j-1} - 2 \cdot U_{i,j} + U_{i,j+1}. \end{cases}$$

D'où la forme explicite de la discrétisation de Δu et de $\text{div}(g)$:

$$\Delta u = \frac{\partial^2 U}{\partial x^2} + \frac{\partial^2 U}{\partial y^2} = U_{i-1,j} + U_{i+1,j} + U_{i,j-1} + U_{i,j+1} - 4 \cdot U_{i,j},$$

et,

$$\text{div}(g) = \frac{\partial U}{\partial x} + \frac{\partial U}{\partial y} = \frac{1}{2}(U_{i-1,j} - U_{i+1,j} + U_{i,j-1} - U_{i,j+1}).$$

Soit :

$$\Delta u = \frac{1}{(\Delta x)^2} L_m U + U \frac{1}{(\Delta y)^2} L_n = L_m U + U L_n,$$

et,

$$\text{div}(g) = D_m G_x + G_y D_n^T.$$

Avec G_x et G_y les formes discrétisées de g_x et g_y respectivement, et L_m , L_n , D_m et D_n les matrices suivantes :

$$L_m = L_n = \begin{bmatrix} 4 & 1 & 0 & \cdots & 0 & 0 \\ 1 & -4 & 1 & \cdots & 0 & 0 \\ 0 & 1 & \ddots & \ddots & \ddots & 0 \\ \vdots & \vdots & \ddots & \ddots & 1 & 0 \\ 0 & 0 & \ddots & 1 & -4 & 1 \\ 0 & 0 & 0 & \cdots & 1 & 4 \end{bmatrix},$$

et

$$D_m = D_n = \frac{1}{2} \begin{bmatrix} 0 & 1 & 0 & \cdots & 0 & 0 \\ -1 & 0 & 1 & \cdots & 0 & 0 \\ 0 & -1 & \ddots & \ddots & \ddots & 0 \\ \vdots & \vdots & \ddots & \ddots & 1 & 0 \\ 0 & 0 & \ddots & -1 & 0 & 1 \\ 0 & 0 & 0 & \cdots & -1 & 0 \end{bmatrix}.$$

Ce qui nous donne à partir de (L) et par application du masque M :

$$(L_d) \quad (L_m U + U L_n) * M = (D_m G_x + G_y D_n^T) * M,$$

Ce problème peut être résolu grâce à l'algorithme du gradient conjugué de la partie 2 car il satisfait toutes les conditions nécessaires à son utilisation :

- Les matrices masquées $(L_m U + U L_n) * M$ et $(D_m G_x + G_y D_n^T) * M$ sont bien comprises dans l'espace vectoriel E .
- L'espace vectoriel E est muni d'un produit scalaire, à savoir : $\langle \cdot, \cdot \rangle = \text{Trace}(\cdot^T \cdot)$.
- La forme obtenue précédemment est une forme quadratique de même forme que l'équation de Sylvester vue plus tôt, convexe car les matrices de Laplace sont définies positives et symétriques.

On suppose $g = \nabla \varphi$, avec φ une fonction de classe $\mathcal{C}^2$ de $\mathbb{R}^2$ dans $\mathbb{R}$. On a alors :

$$\Delta u = \text{div}(g) \iff \Delta u = \text{div}(\nabla \varphi) \iff \Delta u = \frac{\partial^2 \varphi}{\partial x^2} + \frac{\partial^2 \varphi}{\partial y^2} \iff \boxed{\Delta u = \Delta \varphi}$$

Et toujours $u = f$ sur $\partial \Omega$.

Ce qui nous donne ainsi :

$$(L_{\nabla}) \quad \begin{cases} \Delta u = \Delta \varphi & \text{à l'intérieur de } \Omega, \\ u = f & \text{sur } \partial \Omega. \end{cases}$$

Si l'on suit le même fil de pensée que celui qui nous a mené à (L_d) , on a :

$$\boxed{\Delta \varphi = \frac{\partial^2 \Phi}{\partial x^2} + \frac{\partial^2 \Phi}{\partial y^2} = \Phi_{i-1,j} + \Phi_{i+1,j} + \Phi_{i,j-1} + \Phi_{i,j+1} - 4 \cdot \Phi_{i,j}}$$

Où Φ représente la forme discrétisée matricielle de φ . D'où :

$$\Delta \varphi = \frac{1}{(\Delta x)^2} L_m \Phi + \Phi \frac{1}{(\Delta y)^2} L_n = L_m \Phi + \Phi L_n$$

Ce qui nous donne finalement, d'après $\Delta u = \Delta \varphi$:

$$\boxed{(L_{\nabla d}) \quad (L_m U + U L_n) * M = (L_m \Phi + \Phi L_n) * M}$$

Il est ainsi possible d'utiliser l'algorithme du gradient conjugué afin de résoudre le problème :

$$(\mathcal{R}_{\text{restauration}}) \quad (L_m U + U L_n) * M = -(L_m (F * (1_{m,n} - M)) + (F * (1_{m,n} - M)) L_n) * M$$

3.2.2 Application 1 :



Figure 10: Image avant le programme



Figure 11: Image après le programme

Grâce à la fonction *relin*, il est ensuite possible de concentrer les efforts de calcul sur une image recentrée autour de la zone de travail.

On obtient ces images :



Figure 12: Image avant le programme



Figure 13: Image après le programme

On peut noter que sur la première a été appliquée le masque dessiné précédemment. Seulement on a eu des problèmes ; ainsi nous n'avons pas réussi à résoudre ($\mathcal{R}_{restoration}$). En effet, on obtient l'image suivante :

4 Conclusion

Ce bureau d'études nous a permis de pouvoir relire de nombreux concepts fondamentaux en mathématiques et en programmation. Tout d'abord, il nous a offert l'occasion d'étudier l'appliquer des équations d'Euler-Lagrange à deux variables, ainsi que de comprendre et de généraliser l'algorithme du gradient conjugué.

En parallèle, ce bureau d'études a également enrichi nos compétences en programmation, et notamment dans le domaine du traitement d'images mettant en jeux tous les concept mathématique vue tout au long de ce BE de mathématique. Nous avons aussi pu tester et valider des concepts complexes, renforçant ainsi notre compréhension tant théorique que pratique.